Analítica Computacional para la Toma de Decisiones
IIND-4130
Proyecto 1- Analítica de resultados Saber 11
Autores:

Ana M. Sánchez - 202013587
Luna M. Rojas – 202112863
Juan C. Hernández – 201920938

Procesamiento de Data inicial

Inicialmente, se crearon buckets en Amazon S3 para organizar el flujo de datos del proyecto:

- Un bucket de entrada, donde se cargó el archivo CSV completo correspondiente a la base de datos original.
- Un bucket de salida, destinado a almacenar resultados procesados y archivos generados por consultas posteriores.

Creación de buckets en Amazon S3.

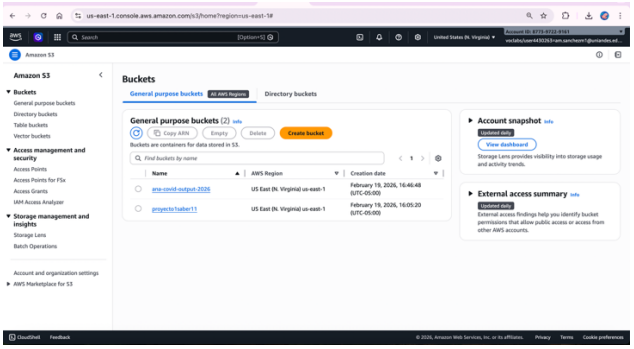

Estructura interna del bucket de entrada con el archivo CSV cargado.

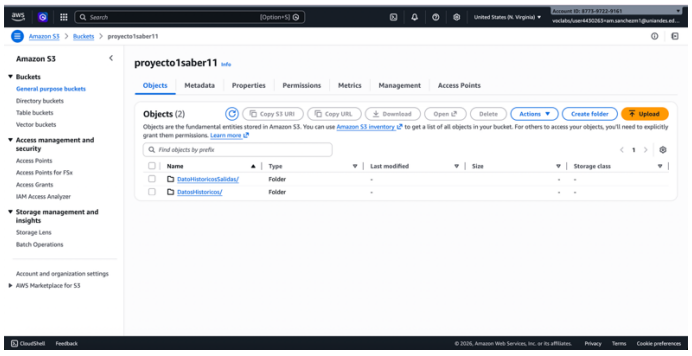

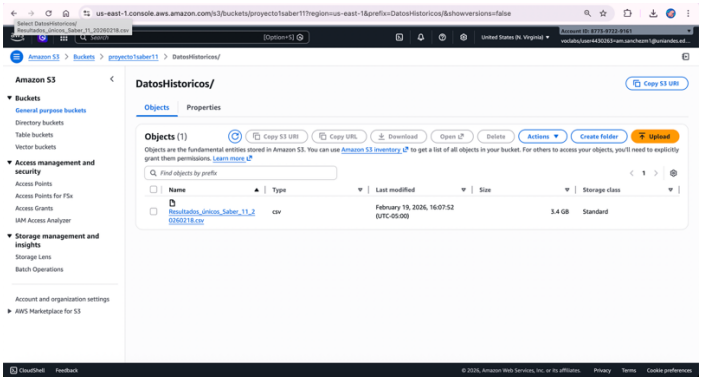

Posteriormente, en Amazon Athena se creó un *Workgroup* para organizar y gestionar las consultas SQL del proyecto, incluyendo la configuración de la ubicación de resultados en el bucket de salida.

A través del Workgroup se procedió a:

- Crear la base de datos del proyecto.
- Configurar la ubicación de almacenamiento de resultados de consultas.
- Garantizar trazabilidad y control sobre la ejecución de queries.

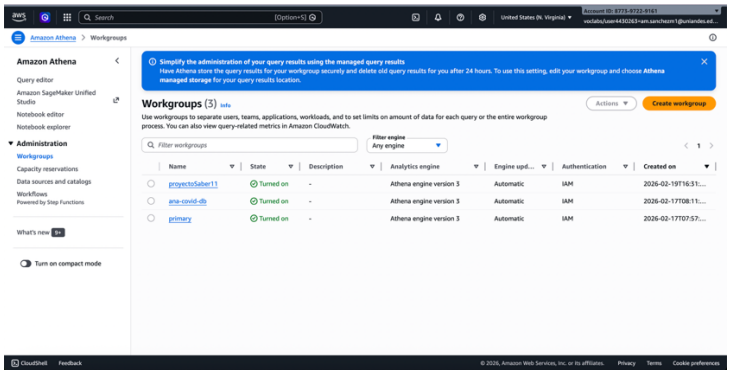

Para estructurar los datos y permitir su consulta eficiente, se utilizó AWS Glue Data Catalog. El proceso incluyó:

1. Creación de un Crawler**.**
2. Configuración del crawler apuntando al bucket de entrada.
3. Ejecución del crawler para:
    - Detectar automáticamente el esquema del archivo CSV.
    - Generar la tabla correspondiente en el Data Catalog.
    - Inferir tipos de datos iniciales.

Posteriormente, se realizaron ajustes manuales en la tabla creada, modificando algunos formatos de columnas (tipos de datos) con el fin de garantizar consistencia y correcta interpretación en Athena.

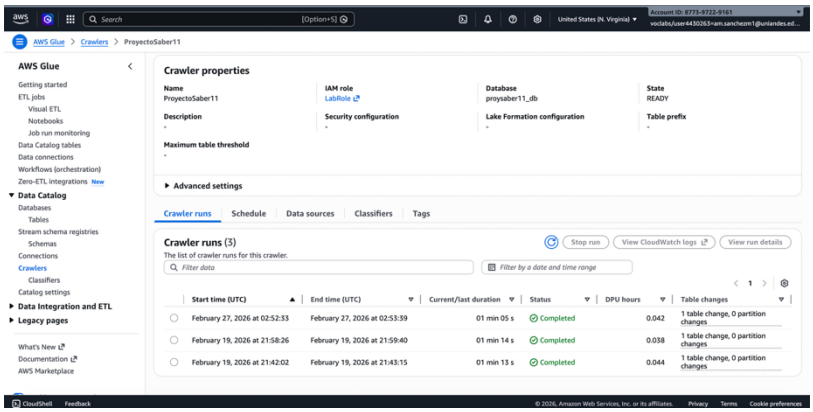

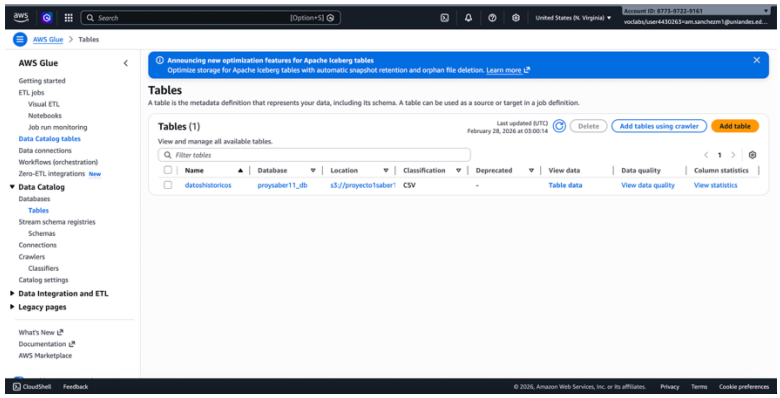

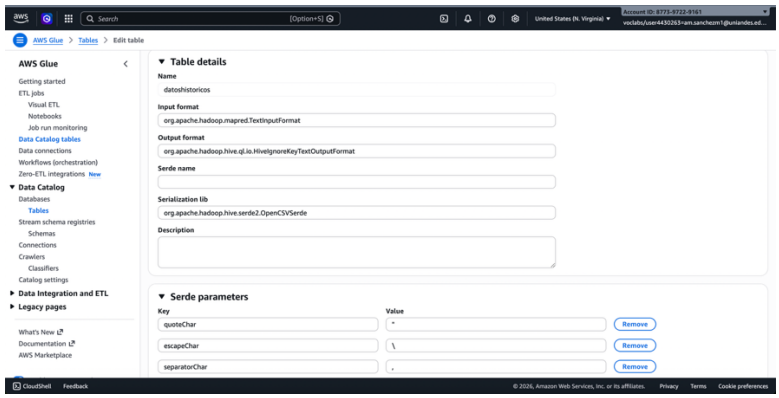
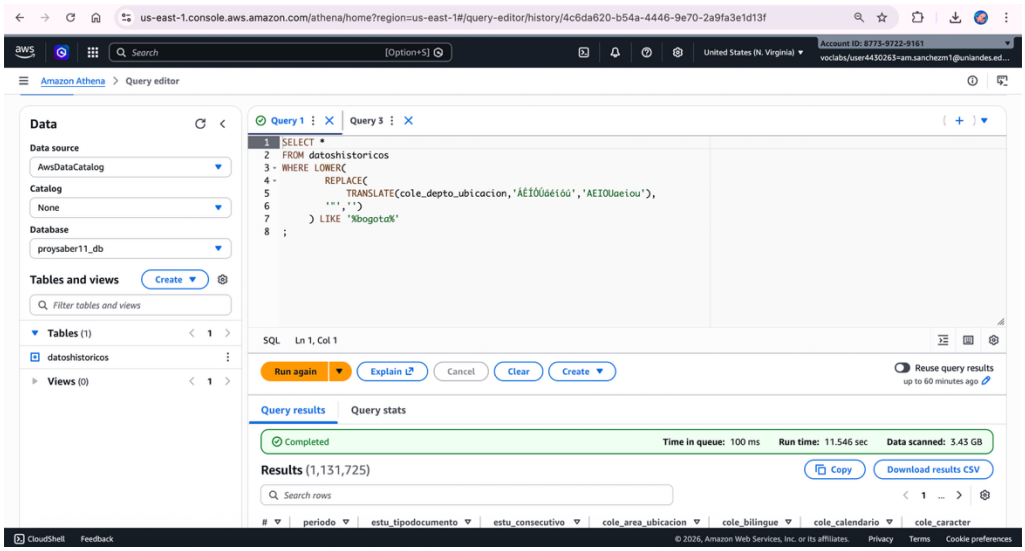
Finalmente, se utilizó Amazon Athena para realizar consultas SQL sobre la base de datos catalogada. En esta etapa se: