Analítica Computacional para la Toma de Decisiones
IIND-4130
Proyecto 1- Analítica de resultados Saber 11

Autores:
Ana M. Sánchez - 202013587
Luna M. Rojas – 202112863
Juan C. Hernández - 201920938

1. Contexto - Todos

El examen Saber 11 es una prueba estandarizada aplicada en Colombia que evalúa el desempeño académico de los estudiantes al finalizar la educación media. Estos resultados son utilizados como un indicador clave de la calidad educativa y como criterio de acceso a la educación superior. En Bogotá D.C., existen diferencias geográficas entre los colegios, particularmente entre aquellos ubicados en zonas urbanas y rurales. Estas diferencias pueden estar asociadas a factores como el acceso a recursos educativos, infraestructura, condiciones socioeconómicas y calidad institucional, los cuales pueden influir en el rendimiento académico de los estudiantes. Por esta razón, es relevante analizar si la ubicación del colegio influye en el desempeño académico.

2. Preguntas de negocio - Todos

a) ¿Existen diferencias significativas en el puntaje global del ICFES entre los distintos estratos socioeconómicos en Bogotá D.C.? **Juan Camilo**
b) ¿Cómo influyen las características institucionales del colegio (naturaleza y bilingüismo) en los puntajes del ICFES en Bogotá D.C.? **Ana**
c) ¿Existen diferencias en el desempeño del ICFES según la ubicación geográfica del colegio y otras características académicas asociadas en Bogotá D.C.? **Mariana**

3. Selección, limpieza y alistamiento de datos – Mariana

En esta fase se utilizaron los datos correspondientes a los resultados de la prueba Saber 11, obtenidos desde el portal de Datos Abiertos de Colombia. El archivo CSV original fue cargado en un bucket de Amazon S3, lo que permitió su almacenamiento seguro y su posterior procesamiento en la nube mediante Amazon Web Services (AWS).

Posteriormente, se utilizó AWS Glue para crear un crawler que identificó automáticamente el esquema del archivo y generó una tabla estructurada en la base de datos saber11_db. Durante este proceso de catalogación y definición del esquema, se realizó la tipificación automática de variables, lo que permitió identificar campos numéricos y categóricos. Algunas variables fueron interpretadas inicialmente como texto y presentaban comillas dobles heredadas del formato original del CSV, situación que fue considerada en las etapas posteriores de limpieza.

Una vez estructurada la tabla, se empleó AWS Athena para ejecutar consultas SQL sobre el dataset. En esta etapa se detectó que el nombre de Bogotá aparecía registrado de múltiples formas (con y sin tilde, con comillas, en mayúsculas y minúsculas). Para garantizar la correcta selección de registros, se implementó un filtro robusto basado en la normalización del texto y el uso del operador LIKE, permitiendo capturar todas las variantes asociadas a la ciudad. Como resultado, se obtuvo un subconjunto de datos correspondiente exclusivamente a Bogotá.

Los resultados de esta consulta fueron exportados en formato CSV para su procesamiento en Python. El proceso de limpieza y alistamiento final se realizó en Python utilizando la librería pandas, con el objetivo de garantizar la consistencia y calidad del dataset. En esta etapa:

- Se estandarizaron los valores de texto mediante la eliminación de espacios innecesarios y la unificación del formato de escritura.
- Se verificó y consolidó la correcta conversión de variables numéricas, incluyendo los puntajes de las pruebas y variables socioeconómicas del hogar, asegurando su formato adecuado para análisis estadístico.

- Se normalizaron variables categóricas binarias como fami_tieneinternet y fami_tienecomputador, restringiéndolas a los valores válidos “SI” y “NO”, y asignando valores nulos a registros inconsistentes.
- Se eliminaron registros sin información en la variable punt_global, dado que esta es fundamental para el análisis del desempeño académico.
- Se depuraron registros duplicados utilizando el identificador único estu_consecutivo, garantizando la unicidad de cada estudiante.

Como parte del proceso de alistamiento, se creó la variable estrato_num, que representa el estrato socioeconómico en formato numérico, facilitando su análisis cuantitativo. Finalmente, se seleccionaron únicamente las variables relevantes para responder las preguntas de negocio y se exportó el dataset limpio en el archivo saber11_bogota_limpio.csv, listo para el análisis exploratorio, la visualización y la construcción de herramientas de apoyo a la toma de decisiones. Como resultado, se obtuvo un dataset estructurado, consistente y alineado con los objetivos del proyecto, que constituye la base para las siguientes fases analíticas.

4. Pregunta 1

Se formulo esta pregunta con el objetivo de analizar posibles desigualdades educativas asociadas a las condiciones socioeconómicas. El estrato socioeconómico en Colombia es un indicador ampliamente utilizado para aproximar el nivel de ingresos, acceso a servicios y condiciones materiales del hogar, factores que pueden influir en el desempeño académico de los estudiantes. Desde el punto de vista analítico, el estrato es una variable categórica, mientras que el puntaje global es una variable numérica continua, lo que permite aplicar herramientas de análisis comparativo para identificar patrones y diferencias significativas entre grupos. A continuación, se muestran las estadísticas encontradas:

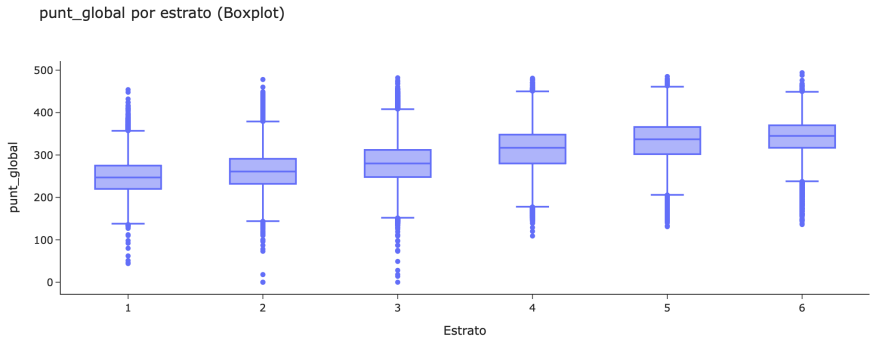

Estrato	Numero	Promedio	Mediana
1	56539	248.36	247
2	235665	262.04	261
3	179635	280.12	280
4	40667	312.58	317
5	13981	330.38	337
6	10128	339.48	345

A simple vista, en el boxplot se observa que las medias del puntaje global aumentan a medida que lo hace el estrato, sin embargo, para las pruebas estadísticas se realizó un análisis ANOVA, obteniendo un p-value de $2x10^{-16}$, sin embargo, al comprobar los supuestos para el análisis no cumplió con la homogeneidad de varianzas. Por lo tanto, se recurrió a una prueba no paramétrica que no dependiera de los supuestos de la ANOVA, para esto se usó la prueba Kruskal-Wallis planteando las siguientes hipótesis:

$$H_0: No\ existen\ diferencias\ significativas\ del\ puntaje\ global\ entre\ medias$$
$$H_a: Se\ rechaza\ la\ hipotesis\ nula$$

En esta prueba, se obtuvo un p-value de $2.2x10^{-16}$, como es menor a 0.05 (significancia), se rechaza la hipótesis nula y se concluye que existen diferencias significativas entre por lo menos dos medias. Con esta información, se calcularon algunas variaciones porcentuales pertinentes para el estudio:

Estrato	Variación
"1-2"	5.51%
"2-3"	6.90%
"3-4"	11.59%
"4-5"	5.69%
"5-6"	2.75%

La tabla evidencia que el puntaje global promedio aumenta de manera sostenida a medida que se incrementa el estrato socioeconómico. El mayor crecimiento relativo se presenta entre los estratos 3 y 4 (11.59%), lo que sugiere un salto importante en desempeño académico en ese tramo. Sin embargo, el crecimiento se desacelera en los estratos más altos (4-5 y 5-6), indicando que la brecha es más pronunciada en los niveles medios que en los superiores. Al comparar el estrato más bajo con el estrato más alto, la variación acumulada es de 36.69%, equivalente a una diferencia absoluta de aproximadamente 91 puntos en promedio, lo que confirma la existencia de una brecha significativa en el rendimiento académico asociada al nivel socioeconómico. Estos resultados sugieren que la educación o preparación para las pruebas saber 11 pueden ser de mejor calidad en estratos más altos. Ya que el estrato socioeconómico es un indicador para aproximar el nivel de ingresos y acceso a servicios, puede que la brecha se deba también a que los estudiantes cuyo ingreso es mayor, accedan a servicios particulares de preparación para el examen o educación más personalizada.

5. Pregunta 2

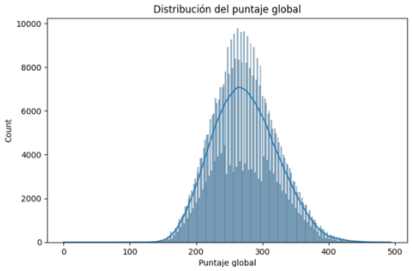

El puntaje global presenta una media de 273.72 puntos y una desviación estándar de 48.68, con una distribución aproximadamente simétrica y concentrada entre 239 (Q1) y 306 (Q3). La forma de la distribución sugiere un comportamiento cercano a normalidad, con presencia de algunos valores atípicos en los extremos. La muestra analizada incluye 536.615 estudiantes, lo que otorga alta robustez estadística a los resultados obtenidos.

El análisis descriptivo por naturaleza institucional muestra:

- **Colegios no oficiales**
  - Media: 288.23
  - Mediana: 289
  - Desviación estándar: 52.38
  - n = 258.944
- **Colegios oficiales**
  - Media: 260.19
  - Mediana: 259
  - Desviación estándar: 40.51
  - n = 277.671

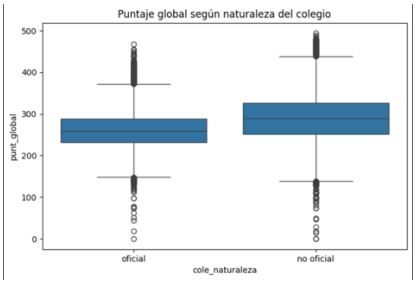

Se observa una diferencia aproximada de **28 puntos** a favor de los colegios no oficiales. La prueba t para muestras independientes arroja: Estadístico t = -218.26 y p-value < 0.001. Dado el valor extremadamente pequeño del p-value, se concluye que existe una diferencia estadísticamente significativa entre ambos grupos. Por tanto, la naturaleza del colegio influye en el desempeño del puntaje global del ICFES.

Para el análisis se excluyeron los registros clasificados como “SIN REGISTRO”, dado que no representan una categoría institucional definida.

Resultados:

- **No bilingües (n)**
  - Media: 272.92
  - Mediana: 271
  - Desviación estándar: 47.36
- **Bilingües (s)**
  - Media: 349.97
  - Mediana: 353
  - Desviación estándar: 40.11

- n = 442.305
- n = 15.209

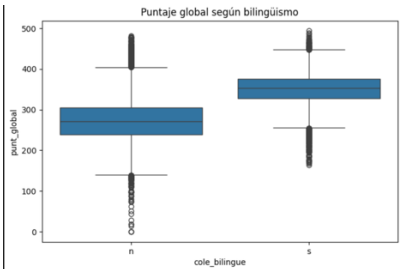

La diferencia promedio es de aproximadamente **77 puntos**, lo cual representa una brecha sustancial en el desempeño.

La prueba t arroja: Estadístico t = 231.47 p-value < 0.001. Esto confirma que la diferencia es estadísticamente significativa.

El puntaje global del ICFES presenta una media general de 273.72 puntos, con una desviación estándar de 48.68. La distribución es aproximadamente simétrica y concentrada entre 239 y 306 puntos (entre el primer y tercer cuartil). Existen diferencias en el puntaje global según la naturaleza del colegio. Los colegios no oficiales presentan un promedio de 288.23 puntos. Los colegios oficiales presentan un promedio de 260.19 puntos. La diferencia aproximada es de 28 puntos. La prueba t para muestras independientes indica que esta diferencia es estadísticamente significativa ($p < 0.001$). Existen diferencias en el puntaje global según el bilingüismo del colegio (excluyendo "SIN REGISTRO"). Los colegios no bilingües presentan un promedio de 272.92 puntos. Los colegios bilingües presentan un promedio de 349.97 puntos. La diferencia aproximada es de 77 puntos. La prueba t indica que esta diferencia es estadísticamente significativa ($p < 0.001$).

6. Pregunta 3

Objetivo del análisis
Determinar si existen diferencias significativas en el puntaje global del ICFES entre estudiantes de colegios ubicados en zonas urbanas y rurales en Bogotá D.C., con el fin de identificar posibles desigualdades educativas que puedan orientar la toma de decisiones.

2. Análisis de datos

Descripción de los datos: Se utilizó una base de datos limpia de estudiantes que presentaron el examen Saber 11 en Bogotá D.C., la cual incluye el puntaje global (punt_global) y la variable de ubicación del colegio (cole_area_ubicacion), clasificada en: URBANO y RURAL.

Inicialmente, se analizó la distribución de estudiantes por zona, encontrándose una marcada concentración en el área urbana (531.758 estudiantes) frente a la rural (4.857 estudiantes). Posteriormente, se calculó el promedio del puntaje global, evidenciando que la zona rural presenta un promedio ligeramente superior (283,29 puntos) en comparación con la zona urbana (273,63 puntos). No obstante, esta diferencia debe interpretarse con cautela debido al fuerte desequilibrio en el tamaño de las muestras entre ambas zonas.

Análisis gráfico

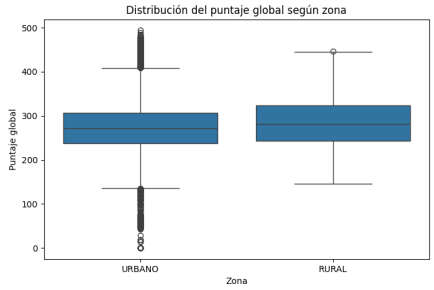

Boxplot: El diagrama de caja mostró que ambas zonas presentan distribuciones similares, aunque la zona rural presenta una mediana ligeramente superior. Esto indica que el desempeño de los estudiantes rurales tiende a ser mayor en comparación con los urbanos.

Ilustración 1. Bloxplot Pregunta de Negocio 2

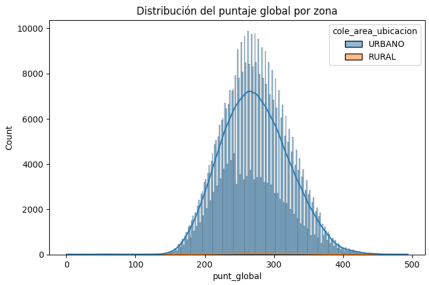

Ilustración 2. Histograma Pregunta de Negocio 2

Histograma: El histograma muestra que ambas zonas tienen distribuciones similares, pero la zona rural presenta una ligera concentración en puntajes más altos, lo que refuerza las diferencias entre zonas.

Análisis estadístico
Se realizó una prueba estadística T-test para determinar si la diferencia entre los grupos es significativa.
Resultado:

```
urbano = df[df["cole_area_ubicacion"]=="URBANO"]["punt_global"]

rural = df[df["cole_area_ubicacion"]=="RURAL"]["punt_global"]

resultado = stats.ttest_ind(urbano, rural)

resultado
0.4s
TtestResult(statistic=np.float64(-14.404937530258652), pvalue=np.float64(4.913612458427487e-47), df=np.float6
```

Ilustración 3. Resultados T-test Pregunta de Negocio 2

- Estadístico t: -14.40
- Valor p: 4.91×10^{-47}

Dado que el valor p es mucho menor que 0.05, se concluye que la diferencia es estadísticamente significativa.
Esto significa que la diferencia observada no es producto del azar.
Conclusión: Sí existen diferencias significativas en el desempeño del ICFES entre zonas en Bogotá, ya que los estudiantes de área rural obtienen en promedio puntajes ligeramente mayores que los de área urbana, lo que evidencia que la ubicación del colegio influye en el rendimiento académico y es relevante para la toma de decisiones educativas.

7. Diseño y desarrollo del tablero – Juan Camilo

En primer lugar, para la creación del tablero se definieron que graficas se querían utilizar para cada pregunta y que inputs tendría el usuario a su disposición para las visualizaciones. Por lo que el primer grafico se realizó respondiendo a la pregunta 1 acerca del estrato socioeconómico, para este, se decidió dar dos opciones de visualización (boxplot y violín), para esto, se uno un RadioItems, en donde el usuario da clic en el tipo de grafico que quiere visualizar. También, pese a que la respuesta de la pregunta solo requiere el puntaje global, se decidió brindarle la opción de escoger que puntaje quiere visualizar, por lo que se agregó un Dropdown.

Teniendo los inputs que se querían realizar, se agregó en el html.Div la gráfica y una tabla resumen adicional que mostrara las estadísticas (número de datos, promedio y mediana) de cada uno de los estratos, teniendo en cuenta que la visualización depende también del input del puntaje que quiere observar el usuario. Luego, se procedió a realizar los callbacks y la función de esta gráfica y tabla, donde se tenían los dos inputs, correspondientes al dropdown y al RadioItem, y dos outputs, correspondientes a la gráfica y a la tabla que retorna la función. A grandes rasgos, la función asociada a este callback contiene un condicional para que cuando el usuario decida que grafico quiere visualizar la función escoja la coincidencia y retorne el esperado por el usuario. El código a detalle, lo puede encontrar en el archivo Dashboard.py.

Posteriormente, bajo la gráfica y la tabla del puntaje vs los estratos, se ubicó la gráfica para responder la segunda pregunta que estudia el puntaje dependiendo de la naturaleza del colegio (oficial = Publico, no oficial = Privado). Para este caso, se utilizaron dos inputs, el primero fue otra vez un Dropdown en el que el usuario escoge el puntaje que quiere observar, y el segundo fue otro RadioItem en que el usuario podía escoger el tipo de grafico que quería observar. Para la solución de esta pregunta, se decidió emplear en el dashboard un histograma de densidad de probabilidad y un histograma de observaciones, el usuario es el que escoge cual visualizar. Es pertinente este tipo de grafico debido a que se puede observar claramente la probabilidad de que los estudiantes obtengan algunos rangos de puntaje teniendo en cuenta si son de colegio público o de colegio privado y así mismo podrán ver cuántos estudiantes se encuentran en cada rango. Para crear la función asociada al callback de este gráfico, nuevamente se utilizó un condicional que solo hiciera que se visualice el histograma esperado por el usuario.

Luego, para responder a la tercera pregunta, referente a la relación entre la zona de ubicación del colegio y el puntaje de los estudiantes, se realizó nuevamente un boxplot para visualizar claramente la media, percentiles, y máximos y mínimos. Nuevamente el input para esta grafica fue un Dropdown para que el usuario pueda escoger el puntaje que quiere visualizar, y el output es el boxplot observado en el tablero. Sin embargo, para esta pregunta se volvio a implementar otro output con una tabla de resumen agrupara no solo por el área de ubicación del colegio sino también su característica, si es académico, técnico o tiene ambas características. De esta manera se podía visualizar mejor en la tabla y en el boxplot la separación de los datos de cada ubicación y característica del colegio.

Finalmente, se añadieron descripciones y conclusiones breves de cada grafico con un pequeño análisis realizado para que el usuario se sintiera más familiarizado con el tablero y entendiera a la perfección cada una de las secciones de este.

8. Despliegue y mantenimiento – Ana Maria

Despliegue en la nube (AWS EC2)

El tablero desarrollado en Dash fue desplegado en la nube utilizando una instancia de Amazon Web Services (AWS) EC2 con sistema operativo Ubuntu Server. Se configuró una máquina virtual tipo t2.micro, adecuada para aplicaciones web ligeras, y se habilitaron los puertos necesarios en el Security Group (80 para HTTP y 443 para HTTPS), permitiendo el acceso público al tablero.

Posteriormente, el repositorio del proyecto alojado en GitHub fue clonado dentro de la instancia, donde se configuró un entorno virtual de Python e instalaron las dependencias especificadas en el archivo requirements.txt. La aplicación fue ejecutada mediante Gunicorn como servidor de aplicaciones, lo que permite un entorno de producción más estable que el servidor de desarrollo de Dash.

Adicionalmente, se configuró Nginx como proxy inverso para gestionar las solicitudes entrantes y redirigirlas correctamente al puerto interno donde se ejecuta la aplicación. Esto garantiza mayor seguridad, mejor manejo de conexiones y una estructura adecuada para despliegues en producción.

Mantenimiento y disponibilidad del servicio

Con el fin de asegurar que el tablero permanezca en ejecución de manera continua, se configuró un servicio utilizando systemd, lo cual permite que la aplicación se inicie automáticamente al reiniciar la instancia y se reinicie en caso de fallos inesperados. De esta manera, se garantiza alta disponibilidad y estabilidad del servicio.

Asimismo, se implementaron reglas de seguridad adecuadas en el Security Group para controlar el acceso a la instancia, permitiendo tráfico web público mientras se restringe el acceso SSH únicamente a direcciones IP autorizadas. Esta configuración mejora la seguridad del entorno en la nube.

Finalmente, el monitoreo del servicio puede realizarse mediante los registros del sistema (logs), lo que facilita la identificación y corrección de posibles errores, asegurando el correcto funcionamiento y mantenimiento del tablero desplegado.